

# بهینه سازی تشخیص سیگنال با استفاده از Deep CNN در MIMO فوق عظیم

چیتاپون کیوین<sup>۱</sup>، آپینیا اینوک<sup>۲</sup> و پیراپونگ اوتانساکول<sup>۱\*</sup>

<sup>۱</sup> دانشکده مهندسی مخابرات، دانشگاه فناوری سوراناری، ناخون راتچاسیما 30000، تایلند؛  
d6400507@g.sut.ac.th

<sup>۲</sup> گروه مهندسی ارتباطات، دانشگاه صنعتی راجامانگالا آپسان، ناخون راتچاسیما 30000، تایلند؛  
apinya.io@rmuti.ac.th

\* مکاتبات: uthansakul@sut.ac.th؛ تلفن: +66-850865588

**چکیده:** این مقاله به چشم انداز در حال تحول فناوری ارتباطات می پردازد و بر نقش محوری شبکه های 5G و 6G و ظهور درپاسخگویی به تقاضای روزافزون برای انتقال داده با سرعت بالا و دقیق تأکید می کند. ما به پیشرفت های فناوری 5G، به ویژه پیاده سازی فرکانس های موج میلی متری (mmWave) از 30 تا 300 گیگاهرتز، می پردازیم. این پیشرفت ها در بهبود برنامه هایی که نیاز به انتقال و دریافت داده های حجیم دارند، نقش مهمی دارند و توسط سیستم های MIMO (ورودی-خروجی چندگانه) عظیم تسهیل می شوند. با نگاهی به آینده، این مقاله ضرورت فناوری های انتقال داده سریع تر را پیش بینی می کند و تمرکز را به سمت توسعه شبکه های 6G تغییر می دهد. پیش بینی می شود که این شبکه های آینده از سیستم های MIMO فوق حجیم در باند تراهرتز استفاده کنند که در محدوده فرکانسی 0.1 تا 10 تراهرتز کار می کنند. بخش قابل توجهی از تحقیقات ما به بررسی تکنیک های پیشرفته تشخیص سیگنال اختصاص داده شده است که به کاهش تأثیر تداخل و بهبود دقت در انتقال داده ها و ایجاد ارتباط کارآمدتر، حتی در محیط هایی با سطوح بالای نویز، کمک می کند و شامل روش های اعمال صفر (ZF) و حداقل میانگین مربعات خطا (MMSE) است که سنگ بنای رویکرد پیشنهادی ما را تشکیل می دهند. علاوه بر این، تشخیص سیگنال به توسعه فناوری های ارتباطی جدید مانند 5G و 6G که نیاز به راندمان انتقال داده بالا و سرعت پاسخ سریع دارند، کمک می کند. سهم اصلی این مطالعه در کاربرد یادگیری عمیق برای تشخیص سیگنال در سیستم های MIMO فوق عظیم، یک جزء حیاتی از فناوری 6G، نهفته است. ما این رویکرد را با روش های یادگیری ماشین مبتنی بر ELMx موجود، با تمرکز بر راندمان الگوریتمی و عملکرد محاسباتی، مقایسه می کنیم. تجزیه و تحلیل مقایسه ای ما شامل ماشین یادگیری افراطی منظم (RELM) و ماشین یادگیری افراطی مقاوم در برابر داده های پرت (ORELM) بود که در کنار روش های ZF و MMSE قرار گرفتند. نتایج شبیه سازی، برتری شبکه عصبی کانولوشنی ما برای تشخیص سیگنال (CNN-SD) را نسبت به روش های سنتی مبتنی بر ZF، ELMx و MMSE، به ویژه از نظر ظرفیت کانال و نرخ خطای بیت، نشان داد. علاوه بر این، ما کارایی محاسباتی و پیچیدگی کاهش یافته روش CNN-SD را نشان می دهیم که بر مناسب بودن آن برای سیستم های MIMO گسترده آینده تأکید دارد.



**استناد:** کیوین، سی.؛ اینوک، ای.؛ اوتانساکول، پی. بهینه سازی تشخیص سیگنال با استفاده از شبکه عصبی عمیق در MIMO فوق عظیم. *مخابرات* ۵۰:۲۴، ۲۰۲۴. <https://doi.org/10.3390/telecom5020014>. ۲۸-۲۹۵.

**کلمات کلیدی:** تشخیص سیگنال؛ ELM؛ یادگیری عمیق؛ MIMO فوق عظیم

دریافت: ۶ فوریه ۲۰۲۴

اصلاح شده: ۱۸ مارس ۲۰۲۴

پذیرفته شده: ۲۶ مارس ۲۰۲۴

منتشر شده: ۲۹ مارس ۲۰۲۴

## ۱. مقدمه

فناوری ارتباطات بی سیم به طور مداوم در حال تکامل است، به خصوص با توسعه سیستم های چند ورودی چند خروجی (MIMO) که از آنتن های گیرنده و فرستنده متعدد برای انتقال داده استفاده می کنند. این پیشرفت به دلیل افزایش تقاضا برای ظرفیت های انتقال داده بالاتر، که یک جزء حیاتی در نگاه ما به سیستم های ارتباطی 6G است، منجر به مطالعه گسترده سیستم های MIMO عظیم شده است. [۱، ۲] شناخته شده است که فوق عظیم به عنوان یک فناوری کلیدی برای افزایش انتقال داده در شبکه 6 MIMO-۵ در حال حاضر، شبکه های 5G از باندهای فرکانسی مختلفی از جمله زیر 6 گیگاهرتز و موج میلی متری (mmWave) استفاده می کنند و محیط های مجازی و ... را پوشش می دهند.

**حق نشر:** © ۲۰۲۴ توسط نویسندگان. دارنده مجوز MDPI، باز، سوئیچس. این مقاله یک مقاله با دسترسی آزاد است تیکل که تحت شرایط مجوز / licenses/b 4.0/ و <http://creativecommons.org/licenses/by/4.0/> (BY) آن ها Creative Comm Attribution (CC) ها: // توزیع شده است.

اینترنت اشیا (IoT). با این حال، تحقیق و توسعه در مورد 6G در حال انجام است، با هدف پشتیبانی از دستگاه های متصل بیشتر و ظرفیت های بالاتر، در عین حال ارائه نرخ داده سریع تر و تأخیر کمتر از 5G [۶]. علاوه بر این، 6G به دنبال افزایش امنیت و قابلیت اطمینان ارتباطات است و ممکن است کاربردهای جدیدی مانند ارتباطات هولوگرافیک را معرفی کند. فناوری هایی برای هوش مصنوعی و خودروهای خودران نیز در انتظار 6G در حال توسعه هستند. در مقایسه با 5G، انتظار می رود 6G نرخ داده ها را 10 تا 100 برابر افزایش دهد و از نرخ داده های تجربه کاربری تا Tb/s و 10 Gb/s پشتیبانی کند. علاوه بر این، 6G می تواند از فناوری اشتراک گذاری فرکانس انعطاف پذیر برای بهینه سازی استفاده مجدد از فرکانس استفاده کند. فناوری MIMO فوق العظیم، که جنبه ای حیاتی از آینده 6G است، را می توان به چهار حوزه اصلی طبقه بندی کرد: باندهای فرکانسی، حالت انتقال، انتقال هوشمند و شبکه یکپارچه. همانطور که گفته شد، 6G از استفاده از فرکانس های تراهرتز از 0.1 تراهرتز تا 10 تراهرتز پشتیبانی می کند که به توسعه سیستم ها کمک می کند و نیازهای آینده مانند کاربرد هوش مصنوعی، دستگاه های پزشکی یا سیستم های رانندگی خودران را که نیاز به تأخیر کمتر و دقت بالاتر دارند، برآورده می کند. این همچنین شامل دسترسی به اینترنت پرسرعت است که به همه امکان دسترسی به منابع ارتباطی افزایش یافته را می دهد. [۸،۷].

به منظور غلبه بر محدودیت ها و برجسته کردن تفاوت ها در ارتباطات بی سیم، از تکنیک های تشخیص سیگنال مانند اعمال صفر (ZF) و MMSE (حداقل میانگین مربعات خطا) به همراه تکنیک های یادگیری عمیق استفاده می شود [1]. [۹،۱۰]. هدف فناوری 5G فعلی ارائه نرخ داده بالاتر و تأخیر کمتر نسبت به 4G است که کاربردهای جدیدی مانند مجازی سازی و دستگاه های متصل بیشتر را در خود جای می دهد. MIMO فوق العظیم، استفاده از بیش از 128 عنصر آنتن را هم در فرستنده و هم در گیرنده در نظر می گیرد [۱۱] مدل کانال صالح-والنژویلا (SV) توسط بسیاری از محققان انتخاب شده است و در قالب های ارتباطی مختلف، از جمله شکل دهی پرتو ترکیبی، پیش کدگذاری ترکیبی و مالتی پلکسینگ فضایی، قابل اجرا است [۱۲] معماری یادگیری ماشین، به ویژه سیستم های مبتنی بر ELMx، که شامل ELM می شود، به طور گسترده در ارتباطات برای تخمین کانال استفاده می شود [۱۳]، از جمله مقالات مورد علاقه در مورد کاربرد هوش مصنوعی در پیش بینی ترافیک [۱۴].

سهم اصلی این اثر به شرح زیر خلاصه می شود:

- ما CNN-SD را پیشنهاد می کنیم که سه الگوریتم یادگیری ماشین ELM، RELM و ORELM را برای تشخیص سیگنال ادغام می کند. بایاس لایه پنهان و وزن ورودی در CNN-SD به طور تصادفی از توزیع هاتولید می شوند [۱۵-۱۷].
- ما پیش بینی می کنیم که با تعداد بیشتر آنتن ها، پیچیدگی بیشتری وجود خواهد داشت. کاربرد یادگیری عمیق در تشخیص سیگنال، به جای استفاده از روش های پیچیده تر تخمین کانال، به بهبود عملکرد و کاهش پیچیدگی کمک می کند.
- ما یک چارچوب مدل سازی برای یادگیری دقیق و رگرسیون همزمان ایجاد کردیم که اجزای حقیقی و موهومی ماتریس های پیچیده را در لایه های ورودی شبکه های عصبی مصنوعی گنجانده تا خطاهای احتمالی را به حداقل برساند. این رویکرد به ما امکان می دهد پیچیدگی کلی سیستم را کاهش داده و کارایی آن را افزایش دهیم.

نتایج شبیه سازی نشان می دهد که از نظر میانگین مربعات خطا (MSE)، نرخ خطای بیت (BER)، ظرفیت کانال، احتمال قطع برق و زمان محاسبات، CNN-SD برای تشخیص سیگنال عملکرد بهتری داشته است.

ادامه این مقاله به شرح زیر خلاصه شده است: بخش ۲ جزئیات مواد و روش ها را شرح می دهد. الگوریتم پیشنهادی CNN-SD به طور خاص در بخش ۲ بخش ۳ شکل های شبیه سازی برای نشان دادن عملکرد تشخیص سیگنال الگوریتم پیشنهادی ارائه شده است. بخش ۴ نتیجه گیری ها است.

## ۲. مواد و روش ها

برای ساخت مدل سیستم، ما یک چارچوب ارتباطی جامع با تأکید بر فناوری MIMO فوق العظیم، با هدف تسهیل محاسبه طیف متنوعی از نتایج، توسعه دادیم. این موضوع در بخش ... توضیح داده خواهد شد. ۲.۱. از جمله MIMO عظیم و MIMO فوق العظیم.

## ۲.۱. مدل های سیستمی پایه

یک مدل سیستم ساده دارای آنتن های فرستنده (مخ) و آنتن های گیرنده (مخ). رابطه بین سیگنال ارسالی و دریافتی، ماتری پلکسینگ فضایی است. کانال محوشدگی مسطح MIMO بدون حافظه (مدل باند باریک) به صورت زیر داده می شود.

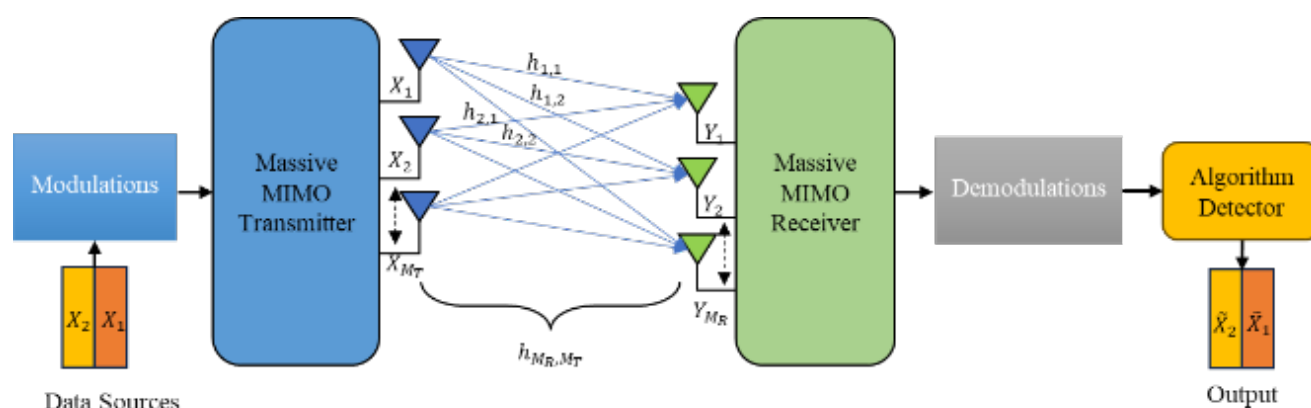
$$(1) \quad Y = Hx + n$$

طبق چارچوب معادله (1)، ماتریس  $H$  که نشان دهنده یک ماتریس کانال پاسخ سیگنال با ابعاد (ست.مخ.مخ) برای روشن شدن کاربرد سیستم های MIMO کلان و MIMO فوق کلان استفاده شده است. علاوه بر این، متغیر  $n$ ، که به عنوان یک بردار نویز گاوسی مختلط سفید افزایشی با ابعاد (ست.مخ.مخ) تعریف می شود. به عنوان یک مدل نویز اولیه در نظریه اطلاعات شناخته می شود. این مدل به طور خاص برای تکرار اثرات فرآیندهای تصادفی متنوعی که معمولاً در محیط های طبیعی مشاهده می شوند، ساخته شده است. بنابراین، نمایش ماتریسی به طور مؤثر رابطه بین سیگنال های ارسالی و دریافتی را ثبت می کند و دینامیک پیچیده انتشار سیگنال را در این سیستم های ارتباطی پیشرفته به شرح زیر نشان می دهد:

$$(2) \quad \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_{M_R} \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1,M_T} \\ h_{12} & h_{22} & \cdots & h_{2,M_T} \\ \vdots & \vdots & \ddots & \vdots \\ h_{M_R,1} & h_{M_R,2} & \cdots & h_{M_R,M_T} \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_{M_T} \end{bmatrix} + \begin{bmatrix} n_1 \\ n_2 \\ \vdots \\ n_{M_R} \end{bmatrix}$$

## ۲.۱.۱. MIMO عظیم

عظیم در مورد پاسخ کانال بسیار مورد تحقیق قرار گرفته است. اول، همانطور که در شکل نشان داده شده است MIMO در این مقاله، ما یک سیستم MIMO عظیم معمولی را بررسی می کنیم. یک نمودار بلوکی برای تحویل منابع داده از  $X$  (بردار سیگنال های ارسالی) به  $Y$  (بردار سیگنال های دریافتی) فرض شده است. در این مدل، پارامتر کانال  $h$  نشان دهنده لینک ارتباطی بین گره های  $X$  و  $Y$  است که به وضوح رفتار معادله (1) را نشان می دهد. کانال های ریلی به دلیل سهولت و دقت در شبیه سازی شرایط داخلی کانال ارتباطی، معمولاً در سیستم های MIMO عظیم استفاده می شوند. آنها همچنین می توانند تأثیر توزیع کم خطر را در تعداد زیادی از ارتباطات بی سیم تخمین بزنند. با این حال، باید توجه داشت که استفاده از کانال های ریلی در MIMO عظیم اغلب منجر به شبیه سازی حالت های کانال به طور ثابت می شود. از آنجایی که شبیه سازی محلی است، این رویکرد ممکن است نتایجی را به همراه داشته باشد که کاملاً با شرایط طبیعی دقیق نیستند. از جمله امکانات آینده 6G، مطالعات انجام شده در آثار مختلف نشان داده است که تعداد فعلی آنتن ها در MIMO عظیم هنوز با محدودیت های عملیاتی در باندهای فرکانسی THz روبرو هستند و از 16 آنتن شروع می شوند. در همین حال، مفهوم MIMO فوق عظیم، که در این تحقیق مورد بحث قرار گرفته است، استفاده از تعداد بسیار بیشتری آنتن، تا 256 عدد، را بررسی می کند که نشان دهنده یک مدل با ظرفیت کامل است. جزئیات بیشتر در بخش بعدی ارائه خواهد شد.



شکل ۱. ساختار سیستم MIMO گسترده

### ۲.۱.۲. MIMO فوق عظیم

این مقاله بر کانال های مختلف بر اساس موقعیت های واقعی بالقوه تمرکز دارد. این موضوع تا حد امکان با استفاده از مدل سیگنال صالح-والنژاد در نظر گرفته شده است، که در آن سیگنال از ترکیبی از بسته های تابشی گسسته تشکیل شده است. این یک مدل معمول برای سیگنال های mmWave است که بازتاب پذیری بالا و انتشار کم دارند. از نظر ریاضی، ماتریس سیگنال پرتو/خوشه را می توان به صورت زیر نمایش داد:

$$H = \sum_{v=1}^{N_{clust}} \sum_{u=1}^{N_{ray}} \beta_{u,v} a_{rx}(AoA_{u,v}) a_{tx}(AoD_{u,v})^* \quad (3)$$

کجائووی تعداد زیرآرایه ها را در می و مرو جایی که سیگنال شامل خوشه است خوشه زاویه خوشه است. در هر گروه، ن/اشعه ها پرتو است، که در آن هر پرتو در حلقه شبیه سازی در نظر گرفته می شود و اثرات چندمسیری که سیگنال با آن مواجه می شود را در نظر می گیرد. خوشه پتانو، وی بهره مختلط را نشان می دهد. علاوه بر این، آئووی تو، وی زاویه انحراف (از آرایه فرستنده) است و آئوآو تو، وی زاویه ورود (از آرایه گیرنده) است. آرایه های ارسال و دریافت بعدی عبارتند از الف تگزاس (آئووی تو، وی) و الف آرایکس (آئوآو تو، وی)، به ترتیب.


این بخش بر تشخیص سیگنال در سیستم های MIMO فوق عظیم تمرکز دارد، که برای انتقال حجم زیادی از داده ها از طریق چندین آنتن فرستنده که در یک ماتریس قرار گرفته اند، و همزمان با سیگنال های تداخل، بسیار مهم است. کمدولاسیون QAM معمولاً برای معرفی و شبیه سازی سناریوهای پیچیده در سیستم های MIMO فوق عظیم، به ویژه در رابطه با طرح های مدولاسیون پیشنهادی برای 6G، به کار می رود. فرآیند مدولاسیون توسط فاز نگاشت صورت فلکی کنترل می شود. این روش شامل دریافت بیت های دودویی به عنوان ورودی، تبدیل آنها به اعداد مختلط و متعاقباً استفاده از آنها به عنوان نماد است. این تجزیه و تحلیل شامل یک سیستم بی سیم چند ورودی چند خروجی (MIMO) است که محوشدگی مسطح را تجربه می کند. این سیستم از چندین آنتن فرستنده استفاده می کند. می و چندین آنتن گیرنده، نماد/یکس (ص) نشان دهنده انتقال انجام شده توسط آنتن است. می در یک لحظه دقیق ص نمادهای ارسال شده در یک بردار با طول سازماندهی می شوند. می مانند یکس (ص) = [یکس (ص)، ...، یکس (ص)]، که به آن اشاره می شود.

$$X_N(p) = |N(p)| \cos(\arg\{N(p)\}) \cos(2\pi f_c p) - |N(p)| \sin(\arg\{N(p)\}) \sin(2\pi f_c p) \quad (4)$$

ک تعداد مدولاسیون هایی است که تمام مدولاسیون های QAM را پوشش می دهد، کجا/تو (تی) / و آرگو (تی) به ترتیب دامنه و فاز سیگنال باند پایه مختلط هستند.

### ۲.۲ روش سنتی

این مقاله بر نقش حیاتی فناوری یا روش های خاص در بهبود یک سیستم چند ورودی چند خروجی (MIMO) در شکل تمرکز دارد. ۲ با بهره گیری از این فناوری، هدف ما افزایش ظرفیت سیستم، در درجه اول با بهبود معیارهای عملکرد مانند نرخ خطای بیتی است. مطالعه ما شامل مقایسه ای جامع بین تکنیک های تشخیص سیگنال مرسوم، از جمله ZF و MMSE، و روش های پیشرفته مبتنی بر الگوریتم ELMx، یعنی RELM، ELM و ORELM، است. علاوه بر این، ما الگوریتم CNN-SD تشخیص سیگنال مبتنی بر شبکه عصبی کانولوشن را معرفی می کنیم و آن را به عنوان یک رویکرد جدید برای افزایش بیشتر عملکرد در سیستم های MIMO پیشنهاد می دهیم.



شکل ۲. نمودار بلوکی نحوه تخمین تشخیص سیگنال.

## ۲.۲.۱ آشکارساز نیروی صفر

اجبار صفر یک مفهوم اولیه در تخمین کانال بود. با تشخیص سیگنال ها، این نوع تخمین به عنوان یک تخمین گرتک بعدی (1D) طبقه بندی می شود، به این معنی که تخمین کانال با استفاده از چرخه های آزمایش انجام می شود. در یک بعد، چه فرکانسی و چه زمانی، تشخیص سیگنال (ZF) میزان مربعات خطا بین سیگنال دریافتی و مقدار تخمینی را کاهش می دهد. در نتیجه، می توان .../یکس زد/اف تشخیص سیگنال توسط

$$\hat{H}_{ZF} = \operatorname{argmin}_{H_{ZF}} \|Y - H_{ZF}X\|^2 \quad (5)$$

از طرف دیگر، تشخیص سیگنال را می توان به شکل زیر نوشت:

$$\tilde{X} = H^+Y \quad (6)$$

سیگنال های پاسخ ضربه در تمام آنتن های فرستنده و گیرنده، کپسوله شده و به شکل ماتریسی ارائه می شوند.

$$\tilde{X}_{ZF} = YH^H(HH^H)^{-1} \quad (7)$$

در این فرمول بندی، (\*) حبه عنوان ترانهاده مزدوج ماتریس تعیین می شود، و (\*)<sup>-۱</sup> مربوط به معکوس ماتریس است.

## ۲.۲.۲ آشکارساز سیگنال MMSE

آشکارساز سیگنال MMSE الگوریتمی است که در بسیاری از آثار به آن اشاره شده است. این الگوریتم مشابه تخمین کانال محاسبه می شود [۱۹، ۱۸]. این دومین مقایسه گری است که ما برای تخمین سیگنال استفاده کردیم، زیرا رایج ترین و پیچیده ترین روش محاسبه است. در نتیجه، دقیق تر از تشخیص سیگنال ZF ارائه شده توسط

$$\tilde{X}_{MMSE} = \operatorname{argmin} \|Y - \tilde{X}_{MMSE}H\|^2 \quad (8)$$

استراتژی تشخیص شامل در نظر گرفتن نویز در طول فرآیند محاسبه است که با ... اندازه گیری می شود.

$$\tilde{X}_{MMSE} = YH^H(HH^H + \frac{\sigma_n^2}{\sigma_h^2}I)^{-1} \quad (9)$$

در این زمینه، **من** نشان دهنده ماتریس همانی با اندازه است **من**، در حالی که **سیگما** <sub>ن</sub> نشان دهنده واریانس نویز، که با نسبت سیگنال به نویز (SNR) نسبت معکوس دارد. علاوه بر این، تمام انرژی های پاسخ سیگنال، همانطور که در شکل نشان داده شده است، نرمال شده اند.

$$E\{|h_{M_R, M_T}|^2\} = \sigma_h^2 \quad (10)$$

## ۲.۳ روش یادگیری ماشین

## ۲.۳.۱ ماشین یادگیری افراطی (ELM)

این مطالعه یک روش یادگیری شتاب یافته برای شبکه های پیش خور تک لایه پنهان (SLFN) معرفی می کند [۲۱، ۲۰]، که برای مدیریت مؤثر شبکه ها با ... طراحی شده است. نگره های نورونی پنهان. علاوه بر این، این روش برای مدیریت [مشکلات] طراحی شده است. در شکل 1 به تفصیل شرح داده شده است ELM الگوریتمی در حوزه یادگیری ماشین که از شبکه های عصبی استفاده می کند، به دلیل کارایی چشمگیر خود در وظایف رگرسیون و سرعت یادگیری بالا شناخته شده است. این امر از طریق تحلیل نظری و اعتبارسنجی تجربی اثبات شده است. چارچوب معماری (ELM) ها است که در نتیجه کارایی و اثربخشی آموزش را افزایش می دهد. ماشین یادگیری شدید SLFN نمونه آموزشی. تمرکز بر افزایش قابل توجه سرعت فرآیند یادگیری در N<sup>۳</sup>، نمایش بصری واضحی از ساختار آن ارائه می دهد. n و m به ترتیب تعداد داده های ورودی و خروجی را نشان می دهند. این تحلیل از فرآیند آموزش ELM با N نمونه آموزشی استفاده می کند (یکس من، تی من)، کجا /یکس من = [یکس من<sub>۱</sub>، یکس من<sub>۲</sub>، ...، /یکس در/تی



نشان‌دهنده داده‌های ورودی است، و  $t_j = [t_{j1}, t_{j2}, \dots, t_{jm}]^T$  نشان‌دهنده داده‌های خروجی. رویکرد تشخیص الگوها در SLFN از یک مدل ریاضی استفاده می‌کند که به شرح زیر است:

$$\hat{t}_j = \sum_{i=1}^{\tilde{N}} \beta_i o(c_i \cdot X_j + V_i), j = 1, 2, \dots, N \quad (11)$$

جمله  $[c_i, V_i]$  بردار وزن ورودی است که به منورون پنهان، و  $t_j = [t_{j1}, t_{j2}, \dots, t_{jm}]^T$  بردار وزن خروجی اشاره دارد. هفتمین گره نورون پنهان. این اصطلاح پنجمین تعصب است. من-هفتمین گره نورون پنهان، و جمله تابع فعال سازی را در SLFNها نشان می‌دهد. برخلاف سایر الگوریتم‌های یادگیری ماشین، ELM می‌تواند به طور تصادفی وزن ورودی را تعیین کند. من و تعصب پنجمین یکی از ویژگی‌های قابل توجه ELM که به عملکرد رگرسیون آن کمک می‌کند، تأیید خطای صفر آن است که امکان تقریب دقیقی از همه موارد را فراهم می‌کند. نمونه‌ها به عنوان من  $t_j = [t_{j1}, t_{j2}, \dots, t_{jm}]^T$  - تی جی - تی جی  $0$ ؛ یعنی بنابراین معادلات را می‌توان به صورت فشرده به صورت زیر بیان کرد


$$H\beta = T, \text{ where } \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_{\tilde{N}} \end{bmatrix}_{\tilde{N} \times m}, T = \begin{bmatrix} T_1 \\ \vdots \\ T_N \end{bmatrix}_{N \times m} \quad (12)$$

$$H(c_1, \dots, c_N, V_1, \dots, V_N, X_1, \dots, X_N) = \begin{bmatrix} o(c_1 \cdot X_1 + V_1) & \dots & o(c_N \cdot X_1 + V_N) \\ \vdots & \dots & \vdots \\ o(c_1 \cdot X_N + V_1) & \dots & o(c_N \cdot X_N + V_N) \end{bmatrix}_{N \times \tilde{N}} \quad (13)$$

کج ماتریس خروجی لایه پنهان شبکه عصبی است و تی ماتریس هدف داده‌های آموزشی است. متغیر نشان‌دهنده ماتریس خروجی لایه پنهان در شبکه عصبی است، در حالی که تی نشان‌دهنده ماتریسی است که شامل اهداف داده آموزشی است. علاوه بر این، به عنوان راه حلی با حداقل بزرگی در رویکرد حداقل مربعات شناسایی شد، که برای سیستم خطی راه حل ELM ضروری است.

$$\hat{\beta} = H^P T \quad (14)$$

کجا (\*) پشه وارون مور-پنروز است.



شکل ۳. تصویری از یک ماشین یادگیری افراطی.

۲.۳.۲. ماشین یادگیری افراطی منظم (RELM)

در حالی که ELM در کاربردهای متعددی مؤثر بوده است، پیاده‌سازی این روش برای جلوگیری از بیش‌برازش و کم‌برازش توصیه می‌شود. همانطور که مطالعه در [۲۲] نشان می‌دهد که پارامترهای نرم کوچک تردد RELM طراحی شده برای SLFNها با تابع سیگموئید می‌تواند منجر به بهبود تعمیم پذیری شود. این معادله همه کاره و قابل اجرا است.

توابع فعال سازی مختلف و گره های نورون پنهان مانند هسته ها، به طور خاص برای حل چالش ها در لایه های پنهان RELM را می توان به عنوان روشی توصیف کرد که توسط آن

$$\underset{(\beta_0, \beta)}{\text{minimize}} \frac{C}{2} \|H\beta + \beta_0 - t\|_2^2 + \frac{(1-a)}{2} \|\beta\|_2^2 + a\|\beta\|_1 \quad (15)$$

وقتی که فقط لایه جریمه عادی (الف) با  $a=0$  در نظر گرفته شود، فرمول RELM به صورت زیر ارائه می شود: سی و پانزده پارامترهای منظم سازی هستند.

$$\hat{\beta} = (H^H H + \frac{I}{C})^{-1} H^H t \quad (16)$$

۲.۳.۳. ماشین یادگیری شدید مقاوم در برابر داده های پرت (ORELM)

اصلاحات اخیر در ORELM با هدف افزایش مهارت آن در ... انجام شده است. لایه های پنهان برای تکنیک های تولید داده های پرت. چنین پیشرفت هایی را می توان از طریق کاربرد ELM [۲۳]، همانطور که توسط شرح داده شده است

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|\tau H\beta - t\|_1 \quad (17)$$

راه حل بهینه برای مسئله بهینه سازی مشخص شده با استفاده از استاندارد بدست می آید. لایه های پنهان.

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|\tau H\beta - t\|_1 + \frac{1}{2C} \|\beta\|_2^2 \quad (18)$$

فرآیندهای خاص الگوریتم مبتنی بر ELMx در الگوریتم خلاصه شده اند. لازم به ذکر است که از الگوریتم مبتنی بر ELMx برای بدست آوردن ماتریس کانال تخمینی در الگوریتم استفاده شده است. ۱.

### الگوریتم الگوریتم های RELM، ELM و ORELM.

۱: ورودی: عدد حقیقی و موهومی/یکس در  $\mathbb{R}^N$ ،  $\mathbb{C}^N$

۲: خروجی:  $\mathbb{X}$ .

۳: مقداردهی اولیه: وزن ورودی را به صورت تصادفی اختصاص دهید من و تعصب پنجم من برای هر نورون پنهان من، کجا من = ۱، ۲، ...

۴: محاسبه ماتریس خروجی لایه پنهان:

۵: برای من = ۱ تا ن انجام دادن

۶: بردار خروجی لایه پنهان را محاسبه کنید من برای هر ورودی/یکس من با استفاده از تابع فعال سازی/ی/یکس/

۷: من = من (چون/یکس من + پنجم من)

۸: پایان برای

۹: ماتریس خروجی لایه پنهان را تشکیل دهید با استفاده از همه من.

۱۰: خروجی با استفاده از معادلات (۱۴)، (۱۶) و (۱۸).

### ۲.۴ روش پیشنهادی

معماری شبکه عصبی کانولوشن پیشنهادی برای تشخیص سیگنال (CNN-SD)

مدلی از یک سیستم پردازش داده های سریالی که به عنوان شبکه عصبی کانولوشن (CNN) شناخته می شود، برای شناسایی و دستکاری داده های با اتصال گسترده توسعه داده شده است. معادله اساسی به شرح زیر است:

$$O(t) = \sum_{z=0}^{L-1} I(z) \cdot w(t-z) + b \quad (19)$$

ای (تی) خروجی کانولوشن یک بعدی را در موقعیت  $t$  روی سیگنال خروجی نشان می دهد.  $I(z)$  مقدار سیگنال داده ورودی را نشان می دهد من در موقعیت  $z$ ، دلیو (تی - زد) با مقدار فیلتر مطابقت دارد دلیو در موقعیت (تی - زد) و  $b$  عبارت بایاس اضافه شده به نتیجه پس از

عملیات کانولوشن در صورت استفاده از بایاس  $b$  طول سیگنال ورودی است و طول فیلتر  $w$  که اندازه فیلتر نیز هست. این معادله نحوه انجام کانولوشن یک بعدی با استفاده از سیگنال ورودی را نشان می دهد. من و فیلتر کنید، و جمله بایاس  $b$  را در صورت وجود لحاظ کنید. برای بدست آوردن  $y$  (تی) در سیگنال خروجی من که مقادیر را از تمام موقعیت های موجود در ضرب و جمع می کند من، ما از فیلتر  $w$  استفاده می کنیم که به اندازه جایجا شده است من موقعیت ها در من برای پردازش لایه کاملاً متصل، داده ها را از لایه قبلی به عنوان برداری از مقادیر متغیر یا مقادیر ویژگی دریافت می کند. اهمیت هر ویژگی را می توان با ضرب آن در یک وزن اضافه کردن یک مقدار بایاس تنظیم کرد تا سیستم بتواند نحوه نمایش داده ها را یاد بگیرد و بین ویژگی ها ارتباط ایجاد کند. لایه خطی

$$y = Wx + b \quad (20)$$

ی بردار خروجی لایه خطی با ابعاد ( است، متر، 1)، که در آن متر تعداد لایه های خروجی مورد نیاز ما است. دلیلی یک ماتریس وزن با ابعاد ( است، متر، ن) و برای ضرب ورودی استفاده می شود. یکس، یکس، یک بردار داده ورودی با ابعاد ( است، ن، 1)، که در آن  $n$  تعداد ویژگی های داده است. ب یک بردار بایاس با بعد ( است، متر، 1) و پس از ضرب در به حاصل اضافه می شود دلیلی واحد خطی یکسو شده (ReLU) یک تابع ریاضی است که معمولاً در شبکه های عصبی و یادگیری عمیق به عنوان یک تابع فعال سازی برای پردازش داده ها در یک لایه استفاده می شود. نتایج به دست آمده با ضرب مقادیر ویژگی در وزن ها و اضافه کردن مقادیر بایاس به یک تابع فعال سازی ارسال می شوند تا مقادیر خروجی این لایه را تولید کنند. تابع فعال سازی ReLU اگر مقدار هر لایه کمتر از صفر باشد، آن را به صفر تنظیم می کند و اگر بزرگتر یا مساوی صفر باشد، همان مقدار را حفظ می کند. ReLU شبکه های عصبی را قادر می سازد تا به طور مؤثر یاد بگیرند و محاسبات آنها را تسریع می کند. نمایش تابعی تابع ReLU شبکه عصبی به شرح زیر است:

$$f(x) = \max(0, x) \quad (21)$$

که در آن اگر مقدار یکس مثبت یا مساوی ۰ باشد، آنگاه مقدار  $f(x)$  خواهد بود یکس خودش. اگر مقدار یکس کمتر از 0 باشد، آنگاه  $f(x)$  صفر خواهد بود. در مرحله اولیه آماده سازی داده ها، نقش اطلاعات بسیار مهم است. این مرحله از نظر روش شناختی به دو دسته اصلی تقسیم می شود، همانطور که در شکل نشان داده شده است. ۴. دسته اول، که به عنوان «داده های آموزشی» تعیین شده اند، شامل داده های متغیر آماده شده از سیستم های MIMO فوق عظیم هستند که برای تسهیل قابلیت های الگوریتم در محاسبه و حفظ حافظه در نظر گرفته شده اند. دسته دوم، که «داده های آموزشی» نامیده می شوند، به گونه ای ساختار یافته اند که الگوریتم را قادر به جذب و بازتولید دقیق خروجی های مورد نظر می کند. تمایز بین این انواع داده هابر اساس ویژگی های پاسخ کانال آنها در سیستم ارتباطی MIMO فوق عظیم پس از مرحله آماده سازی داده ها تعیین می شود. رویه های متوالی الگوریتم های CNN-SD به طور جامع در بخش الگوریتم شرح داده شده اند. ۲، ارائه یک چارچوب مشخص برای گردش کار الگوریتمی.

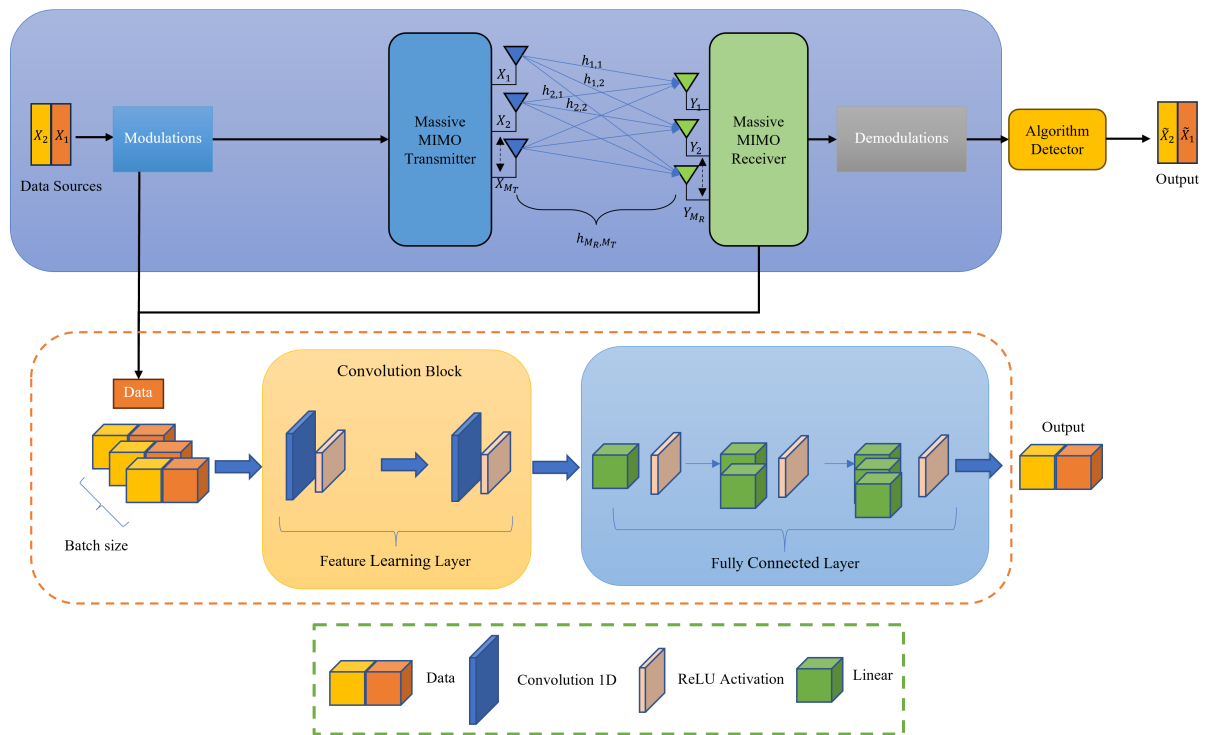
---

#### Algorithm 2 CNN-SD algorithm.

---

- 1: **Input:** Real and Imaginary number  $X \in \mathbb{R}^{n \times l}$ ,  $Y \in \mathbb{R}^{n \times l}$
- 2: **Output:**  $\hat{X}$ .
- 3: **Initialization:** Randomly assign input weight  $W_i$  and bias  $b_i$  for each hidden neuron  $i$ , where  $i = 1, 2, \dots, L$ .
- 4: **procedure** PROCESSING( $X$ )
- 5:    $X_{conv1} \leftarrow \text{ReLU}(W_{conv1} * X + b_{conv1})$
- 6:    $X_{conv2} \leftarrow \text{ReLU}(W_{conv2} * X_{conv1} + b_{conv2})$
- 7:    $X_{flat} \leftarrow \text{Flatten}(X_{conv2})$
- 8:    $X_{fc1} \leftarrow \text{ReLU}(W_{fc1} \cdot X_{flat} + b_{fc1})$
- 9:    $X_{fc2} \leftarrow \text{ReLU}(W_{fc2} \cdot X_{fc1} + b_{fc2})$
- 10:    $X_{fc3} \leftarrow \text{ReLU}(W_{fc3} \cdot X_{fc2} + b_{fc3})$
- 11:    $\hat{X} \leftarrow W_{predict} \cdot X_{fc3} + b_{predict}$
- 12:   **return**  $\hat{X}$
- 13: **end procedure**





شکل ۴. فرآیند CNN-SD.

#### ۲.۵ ظرفیت کانال

مفهوم ظرفیت شانون یک کانال بر حداکثر نرخ داده ای که می توان در یک پهنای باند مشخص (BW) و بانسبت سیگنال به نویز مشخص به آن دست یافت، متمرکز است. این ظرفیت نظری، کاهش نرخ خطای بیت (BER) را نشان می دهد که دستیابی به آن در سناریوهای دنیای واقعی چالش برانگیز است. با این حال، باتکامل تکنیک های طراحی سطح لینک، نرخ داده واقعی برای کانال های نویز به این مرز نظری نزدیک می شود، همانطور که در [بحث شده است. ۲۴] ظرفیت کانال بالا که اغلب با واحد بیت در ثانیه (bps) هرترز یا واحدهای معادل آن اندازه گیری می شود، نشان دهنده توانایی سیستم ارتباطی برای انتقال سریع و مؤثر داده ها است. این ظرفیت به صورت زیر فرموله می شود:

$$C = \log_2 \det \left[ I_{M_R} + \frac{P_t}{P_n M_T} H H^H \right] \quad (22)$$

اینجا،  $M_T$  و  $M_R$  ماتریس همبستگی با ابعاد  $(M_T \times M_T)$  و  $(M_R \times M_R)$  است.  $P_t$  و  $P_n$  توان و نویز سیگنال (SNR) را کمی می کند. در اندازه پاسخ  $(M_R \times M_T)$ ،  $(*)$  اثرات مزاحمتی است. و پهنای باند نسبت نویز سیگنال (SNR) را کمی می کند. در تخمین ظرفیت کانال، بررسی ما شامل پاسخ های کانال به دست آمده از طریق روش LS، روش رایج MMSE و سه رویکرد دیگر ریشه در کاربردهای یادگیری ماشین، یعنی ELM، RELM و ORELM، بود. فرمول محاسبه ظرفیت تخمینی در مدل CNN-SD به شرح زیر است (6) تا (23) تولید شود.

#### ۲.۶ احتمال قطعی برق

یکی دیگر از شاخص های اصلی عملکرد در تکنیک های ارتباطی، احتمال قطع برق است، همانطور که در [بحث شده است ۲۰]. این اغلب به صورت درصد بیان می شود و به وضعیت کانال و تداخل در سیستم بستگی دارد. احتمال قطع، ریسک عدم دریافت یا از بین رفتن سیگنال ارتباطی را اندازه گیری می کند. اگر احتمال قطع کم باشد، سیستم ارتباطی در انتقال داده ها کارآمد است. احتمال قطع را می توان به صورت زیر تعیین کرد:

$$P_{out}(C_{es} < R) \quad (23)$$

کجاءنرخ ظرفیت است. در نتیجه، مطلوب ترین اقدام برای فرستنده، استفاده از رمزگذاری داده ها است. این تصمیم به بهره کانال بستگی دارد.

کافی بودن برای تطبیق با نرخ مورد نظر که به صورت زیر نشان داده شده است در چنین شرایطی، دستیابی به ارتباط قابل اعتماد امکان پذیر می شود؛ در غیر این صورت، قطع ارتباط رخ می دهد. در صورت وجود بهره محوشدگی که با  $h$  نشان داده می شود، می توان کانال را به عنوان کانالی در نظر گرفت که جریان اطلاعات را مجاز می داند. مشروط بر اینکه حجم داده ها از نرخ تعیین شده فراتر رود، چشم انداز رمزگشایی قابل اعتماد قابل دستیابی می شود. احتمال قطع کانال صالح، به عنوان تابعی از نرخ انتقال، را می توان به صورت زیر بیان کرد:

$$P_{out}(R) = 1 - \exp\left(\frac{-2^R - 1}{SNR}\right) \quad (24)$$

پیرو احتمال قطع سیستم را نشان می دهد که با نحوه تشخیص مقصد هنگام تکیه بر سیگنال های دریافتی از گره رله مشخص می شود.

۲.۷ الگوریتم از دست دادن کامل

۲.۷.۱ میانگین مربعات خطا (MSE)

اثربخشی الگوریتم های یادگیری ماشین را می توان از طریق رویکردهای متعددی تجزیه و تحلیل کرد. در نتیجه، میانگین مربعات خطا (MSE) برای تجزیه و تحلیل عملکرد انتخاب شد تا نتایج قطعی حاصل شود. همانطور که توسط مراجع [1] تأیید شده است، ۱۲.۱۱ این معیار که اغلب در ارزیابی عملکرد استفاده می شود، نیاز به محاسبه خطا دارد/یکس، که نشان دهنده اختلاف از  $X$  واقعی است، و سپس میانگین گیری از این خطا. بر اساس این اختلاف، گرادیان تلفات محاسبه شده و برای پس انتشار وزن ها استفاده می شود. مرحله بعدی شامل اعمال گرادیان نزولی در مرحله آموزش بعدی برای کاهش تلفات است. تابع تلفات مورد استفاده در رگرسیون به صورت زیر ارائه می شود.

$$MSE_N = \frac{1}{N} \sum_{i=1}^N (X - \tilde{X}_i)^2 \quad (25)$$

۲.۷.۲ تلفات تمرین

کل تلفات می تواند به ما در بررسی امکان پذیری مجموعه داده ها بین آموزش ها کمک کند، زیرا می تواند محدوده آزمایش برای به دست آوردن یک مجموعه داده مناسب را مشخص کند. در عمل، میانگین تلفات برای هر دسته محاسبه می شود و سپس در تمام دسته ها در یک دوره میانگین گرفته می شود. این یک ارزیابی جامع از عملکرد مدل روی داده های آموزشی ارائه می دهد و به دنبال کردن پیشرفت آن در طول زمان کمک می کند. با توجه به زمان پردازش سریع، محاسبه تعداد کل دوره های آموزشی در دوره ها به شرح زیر انجام می شود:

$$T_B = T_D / B_S \quad (26)$$

کجایی تعداد کل دسته ها است. تی بی اندازه کل داده ها است، و بی اندازه دسته است. برای تعیین تعداد نمونه هایی که در سراسر شبکه توزیع می شوند، اندازه دسته ضروری است. هنگام آموزش یک مدل یادگیری عمیق، میانگین تلفات معمولاً در کل مجموعه داده های آموزشی، در دسته های کوچکی از نمونه ها محاسبه می شود. این به عنوان آموزش دسته ای شناخته می شود. دلیل این امر این است که آموزش مدل روی کل مجموعه داده ها به صورت یکجا می تواند از نظر محاسباتی پرهزینه باشد و همچنین می تواند باعث شود مدل روی داده های آموزشی بیش برآزش (Overfit) داشته باشد.

۲.۷.۳ زیان اعتبارسنجی

فرمول محاسبه ی خطای اعتبارسنجی احتمالاً ۲۵) MSE است، اما ما فقط مقدار داده های اعتبارسنجی را برای محاسبه در نظر گرفتیم، که در آن تعداد دوره ها و  $f$  تابع زیان است. با این حال، زیان اعتبارسنجی را به صورت زیر محاسبه کردیم.

$$V = \frac{1}{M} \sum f(\hat{Y}_d, Y_d) \quad (27)$$

کجا  $\hat{Y}_d$  داده های پیش بینی است و  $Y_d$  در حال آموزش داده است. علاوه بر این، تفسیر نتایج بسیار مهم بود و به سه بخش تقسیم شد: کم برآزش به وضعیتی در سناریوی ۱ اشاره دارد که در آن نتایج نشان می دهد که آموزش اضافی برای

کاهش تلفات تجربه شده در طول فرآیند آموزش. به طور جایگزین، می توانیم داده های آموزشی را با به دست آوردن نمونه های اضافی یا تقویت داده های موجود، بهبود بخشیم. بیش برآزش زمانی رخ می دهد که در سناریوی ۲، تلفات اعتبارسنجی از تلفات آموزش بیشتر شود. در سناریوی ۳، یک برآزش خوب با کاهش تلفات آموزش و اعتبارسنجی و رسیدن به یک نقطه پایدار مشخص می شود.

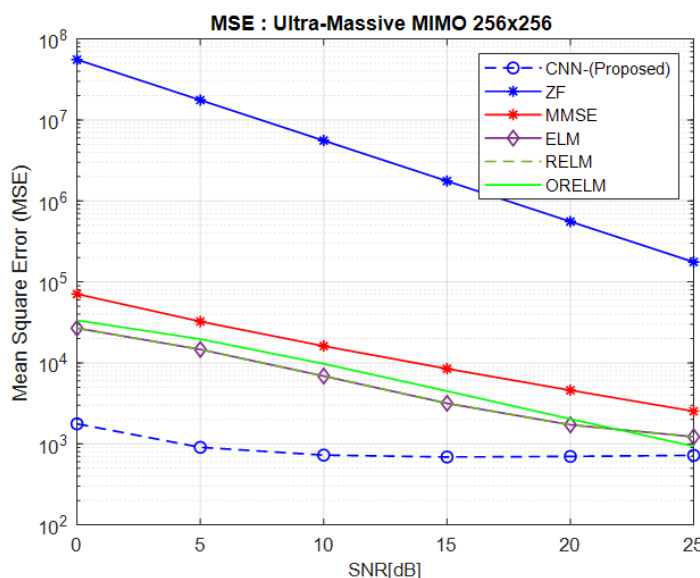
### ۳. نتیجه و بحث

۳.۱. تنظیمات مجموعه داده ها

مجموعه داده مورد استفاده شامل سه جزء بود: داده های آموزشی، داده های آزمایشی و داده های اعتبارسنجی. این اجزا شامل دو مجموعه داده بودند: مجموعه داده های سیگنال دریافتی که با نشان داده می شود. و مجموعه داده های منتقل شده، که به صورت نشان داده می شود/یکس مطابق با اصول سیستم های ارتباطی. ما در مجموع ۱۰۰۰۰۰ مجموعه داده را جمع آوری و شبیه سازی کردیم.

۳.۲. میانگین مربعات خطا (MSE) و میانگین مربعات خطا (BER)


این بخش از مطالعه بر ارزیابی میانگین مربعات خطا (MSE) و نرخ خطای بیت (BER) و همچنین ارزیابی اثربخشی رویکردهای تشخیص سیگنال مبتنی بر صفر (ZF)، حداقل میانگین مربعات خطا (MMSE) و ELMx در تأیید عملکرد چندین الگوریتم CNN-SD تمرکز دارد. این استراتژی ها در سیستم های MIMO فوق عظیم که شامل ۲۵۶ آنتن فرستنده و گیرنده، هر کدام با نگاشت مدولاسیون ۲۵۶QAM و تعداد مشخصی پایلوت بودند، ارزیابی شدند. ویژگی ها و رویکردهای الگوریتم های مبتنی بر CNN-SD و ELMx در بخش الگوریتم ها توضیح داده شده است. و ۲ نتایج عملکرد مقایسه ای میانگین مربعات خطا (MSE) در شکل نشان داده شده است. ۵. اشاره شد که ZF، به دلیل رویکرد ابتدایی ترش، در مقایسه با چهار روش دیگر موفقیت کمتری داشته است. از سوی دیگر، MMSE به دلیل پیچیدگی بیشترش، از روش حداقل مربعات (LS) بهتر عمل کرد. روش مبتنی بر ELMx، یک تکنیک یادگیری ماشین، با استفاده مؤثر از مجموعه داده های آموزشی و آزمایشی بزرگ برای تکرار دقیق داده های لازم، از ZF و MMSE بهتر عمل کرد. رویکرد CNN-SD با نشان دادن عملکرد برتر، که به آرایش ساختاری منحصر به فرد آن نسبت داده می شود، خود را متمایز کرد که برای نتایج استثنایی بهینه شده است.



شکل ۵. عملکرد MSE در سیستم های MIMO فوق عظیم

شکل ۶. شکل ۱ عملکرد BER را برای تمام تکنیک های تشخیص سیگنال در یک سیستم ارتباطی فوق حجیم مبتنی بر MIMO نشان می دهد که شامل ۲۵۶ آنتن فرستنده (MT) و ۲۵۶ آنتن گیرنده (MR) است. SD در CNN- تشخیص سیگنال از رویکردهای اساسی مانند MMSE، LS، و یادگیری ماشین مبتنی بر ELMx عملکرد بهتری داشته است.


نتایج نشان داد که عملکرد BER الگوریتم CNN-SD در بین همه روش ها بهترین بوده است.



شکل ۶. عملکرد BER در سیستم های MIMO فوق عظیم

### ۳.۳ اعتبارسنجی مدل

شکل ۷ عملکرد منحنی یادگیری برازش خوب را برای تلفات آموزش و تلفات اعتبارسنجی نشان می دهد و نشان می دهد که مقادیر در محدوده ۱ تا ۳ درصد گروه بندی شده اند. بنابراین، مدل استعداد بالایی برای یادگیری از خود نشان داد. این مدل می تواند برای پیش بینی دقیق داده های قبلاً دیده نشده مورد استفاده قرار گیرد. از طرف دیگر، می توان آن را به عنوان مدلی نامید که توانایی اعمال دانش خود را بر داده های ناآشنا نشان می دهد. ما ۱۰۰۰۰ مجموعه داده را برای روش پیشنهادی خود به ۶۰٪ داده های آموزشی، ۲۰٪ داده های آزمایشی و ۲۰٪ داده های اعتبارسنجی تقسیم کردیم.

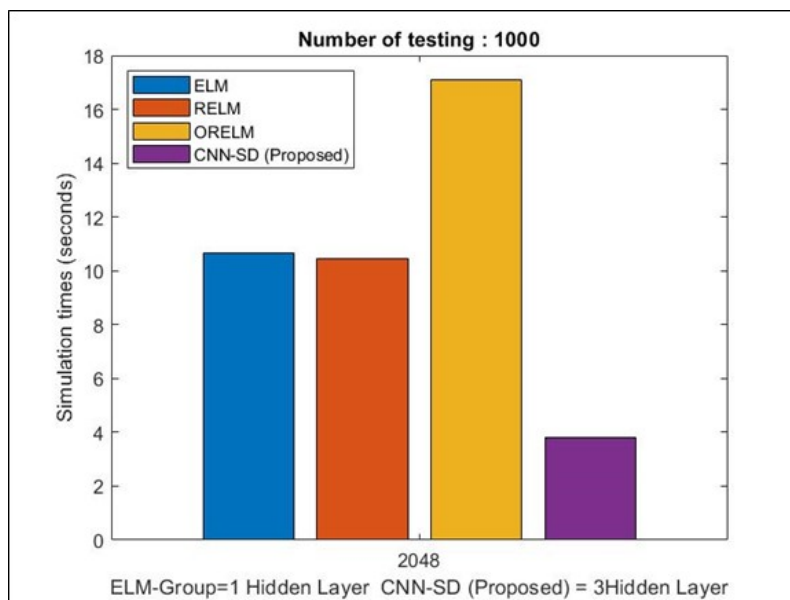


شکل ۷. عملکرد مدل CNN-SD.

### ۳.۴ زمان محاسباتی

شکل ۸ نشان می دهد که زمان محاسبه در مقایسه محاسباتی بین ELMx و CNN-SD، با توجه به پیچیدگی محاسباتی برای

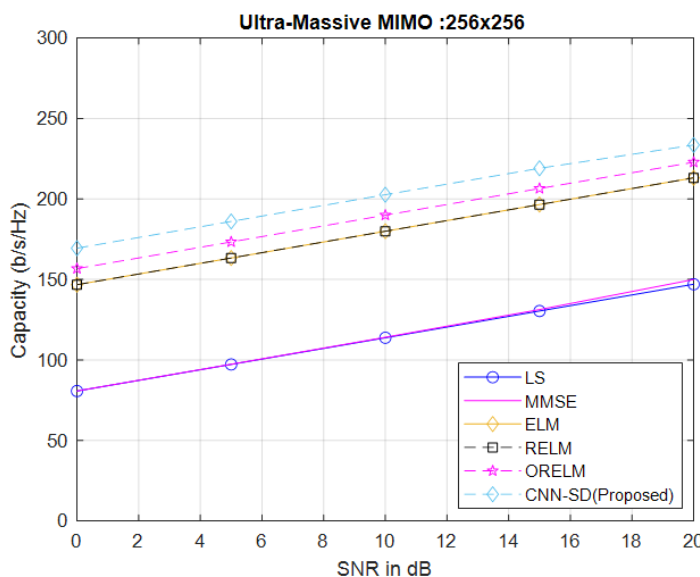
تعدادگره ها از ۲۰۴۸ گره. نتیجه برای ELMx، مانند ELM RELM و ORELM، نشان داد که زمان محاسبات بیشتر از CNN-SD است زیرا مدیریت داده ها در CNN-SD دارای اندازه دسته ای است که می تواند به کاهش استفاده از منابع رایانه ای کمک کند. دلیل این امر این است که آموزش روی یک مجموعه داده بزرگ می تواند زمان ارتباط بین پردازنده ها را کاهش دهد. این می تواند به طور قابل توجهی به کاهش استفاده از منابع رایانه ای و مدیریت داده ها در RAM کمک کند. این امر هنگام آموزش مدل هایی که داده محور هستند یا ساختارهای پیچیده ای دارند، مهم است.



شکل ۸. زمان محاسباتی برای ELMx و CNN-SD.


### ۳.۵ ظرفیت کانال و احتمال قطع برق

تمرکز دیگر این بخش بر معیارهای عملکرد ظرفیت کانال و احتمال قطع برق در سیستم های MIMO فوق العظیم بود. معادله (19) برای پردازش و مقایسه ظرفیت کانال، همانطور که در شکل ها نشان داده شده است، استفاده شد. ۹ و ۱۰.



شکل ۹. عملکرد ظرفیت کانال ELMx و CNN-SD در سیستم های MIMO فوق العظیم.





**شکل ۱۰.** عملکرد احتمال قطع برق ELMx و CNN-SD در شبکه های فوق عظیم سیستم های MIMO

در همین حال، برای تعیین احتمال خاموشی، از معادلات (20) و (21) استفاده شد، همانطور که در شکل نشان داده شده است. <sup>۱۰</sup> نتیجه آزمایش برای ظرفیت کانال در مقابل SNR نشان می دهد که الگوریتم های یادگیری ماشین RELM، ELM و OREL ظرفیت کانال کمتری نسبت به تکنیک های CNN-SD ارائه می دهند. در شکل ۹، عملکرد بسیار خوبی را مطابق با روش نشان داد، همانطور که در شکل نشان داده شده است. <sup>۹</sup> CNN-SD با ظرفیت 128 bps/Hz، است. ELM، RELM و OREL هستند. در نتیجه، این نشان دهنده احتمال قابل توجه ظرفیت بالای کانال در مقایسه با bps/Hz برابر با 116 bps/Hz و OREL و برای bps/Hz برابر با 105 bps/Hz، برابر با 105 bps/Hz، برای ELM فوق عظیم به احتمال زیاد به ظرفیت بالایی دست می یابد. در سطح احتمال 90٪، ظرفیت ها برای MIMO داشت. واضح است که کانال ELMx بیشتر از تکنیک های مبتنی بر bps/Hz ظرفیتی 200 SNRdB در CNN-SD 10، <sup>۱۰</sup>

#### ۴. نتیجه گیری

سیستم های MIMO فوق عظیم، که نشان دهنده پیشرفت های قابل توجه در آینده هستند، آنتن های ارتباطی اضافی و تکنیک ها یا رویه های جدیدی را در خود جای داده اند که می توانند کارایی سیستم و قابلیت های حل مسئله را افزایش دهند. این مقاله بر یافتن روش هایی تمرکز داشت که منجر به ارتباط مؤثرتر و کاهش مشکلات می شوند. یکی از این رویکردها، معرفی تکنیک تشخیص سیگنال یادگیری عمیق SD-CNN در یک سیستم MIMO فوق عظیم بود. نویسندگان از تکنیک های مختلفی برای مقایسه با گروه های یادگیری ماشین مبتنی بر MMSE، LS، ELMx استفاده کردند. سه الگوریتم RELM، ELM و OREL، همراه با CNN-SD پیشنهادی، برای ارزیابی عملکرد آنها در تشخیص سیگنال بررسی شدند. تجزیه و تحلیل BER، MSE، ظرفیت و احتمال قطع برق نشان داد که CNN-SD از سایر الگوریتم ها عملکرد بهتری دارد. بنابراین، برای سیستم های آینده که از MIMO فوق عظیم استفاده می کنند، CNN-SD به عنوان انتخاب بهینه برای تشخیص سیگنال ظاهر می شود. در کارهای آینده خود، هدف ما افزایش اثربخشی روش پیشنهادی خود با استفاده از استراتژی ای است که تکنیک های ترکیب امتیاز و شبکه های عصبی چند مقیاسی را ادغام می کند و همچنین معماری های شبکه عصبی اضافی را برای بهینه سازی عملکرد بررسی می کند.

**مشارکت های نویسنده:** مفهوم سازی، PU و هوش مصنوعی؛ روش شناسی، PU، CK و هوش مصنوعی؛ نرم افزار، CK؛ نظارت، PU و هوش مصنوعی؛ اعتبارسنجی، PU و هوش مصنوعی؛ تحلیل رسمی، PU و هوش مصنوعی؛ تأمین بودجه، PU؛ تحقیق، CK؛ مدیریت پروژه، PU و هوش مصنوعی؛ منابع، PU، CK و هوش مصنوعی؛ گردآوری داده ها، CK؛ نگارش - تهیه پیش نویس اصلی، CK؛ نگارش - بررسی و ویرایش، CK. همه نویسندگان نسخه منتشر شده مقاله را خوانده و با آن موافقت کرده اند.

**تأمین مالی:** این تحقیق هیچ بودجه خارجی دریافت نکرده است.

## بیانیه هیئت بررسی نهادهای قابل اجرا نیست.

بیانیه رضایت آگاهانه: از تمام افراد شرکت کننده در مطالعه، رضایت آگاهانه اخذ شد.

بیانیه دسترسی به داده ها: داده ها درون مقاله موجود است.

تضاد منافع: نویسندگان هیچ گونه تضاد منافی را اعلام نمی کنند.

## منابع

۱. هو، وای. لین، ایکس. دی. بی. ژانگ، اچ. هرناندو، اف. جی. ال. تان، ای. اس. ممتاز، اس. دمیر، او. تی. چن-هو، کی. روندهای فناوری برای MIMO انبوه به سوی 6G، *arXiv:2301.01703*. ۲۰۲۳.
۲. وانگ، ایکس. کونگ، ال. کونگ، اف. کیو، اف. شیبا، ام. آرنون، اس. چن، جی. ارتباطات موج میلی متری: یک بررسی جامع. *مدرس ارتباطات، نظارت و ارزیابی IEEE*. ۲۰۱۸. ۱۶۵۳-۱۶۶۴. [کراس رف]
۳. ژنگ، ی. وانگ، سی ایکس؛ یانگ، آر. یو، ال. لای، اف. هوانگ، جی. فنگ، آر. وانگ، سی. لی، سی. Zhong, Z. اندازه گیری کانال MIMO فوق العاده عظیم در 5G. *گیاگهرتز و یک مدل کانال 6G عمومی. فناوری ترانس. وه. IEEE*. ۲۰۲۲. ۷۲۰۲۲-20-34. [کراس رف]
۴. دپلی، ر.؛ چاندارا، ر.؛ جوردانا، د. فناوری های MIMO فوق عظیم برای شبکه های بی سیم نسل ششم. *مهندسی علوم*. ۲۰۲۱. ۱۶۰۲۱-308-318. [کراس رف]
۵. وانگ، سی ایکس؛ وانگ، جی.؛ هو، اس.؛ جیانگ، زی. اچ.؛ تائو، جی.؛ یان، اف. فناوری های کلیدی در سیستم های ارتباطی بی سیم ترهترت نسل ششم: یک بررسی. *مجله فناوری IEEE Veh*. ۲۰۲۱. ۱۶۰۲۱-۳۷-۲۷. [کراس رف]
۶. فیصل، الف.؛ سری الدین، ج.؛ درجوع، ج.؛ النفوری، تی. وای.؛ آلوینی، ام. اس. سیستم های MIMO فوق عظیم در باندهای ترهترت: چشم اندازها و چالش ها. *مجله فناوری IEEE Veh*. ۲۰۲۰. ۱۵۰۲۰-۳۳-۴۲. [کراس رف]
۷. مرشد، آریو؛ اشرف، ز. بی.؛ هریدون، ای. اچ.؛ موناسینگه، کی.؛ جمالی پور، ای.؛ حسین، ام. اف. یک شبکه عصبی عمیق جداسازی همجوشی مبتنی بر LSTM-CNN برای شکل دهی پرتو هیبریدی MIMO فوق عظیم نسل ششم. *دسترس IEEE*. ۲۰۲۳. ۱۱۰۲۰۲۳-۳۸۶۱۴-۳۸۶۳۰. [کراس رف]
۸. سری الدین، ه.؛ آلوینی، م. س.؛ النفوری، ت. وای. مدولاسیون فضایی فوق عظیم باند ترهترت MIMO. *ارتباطات مناطق IEEE J. Sel.* ۲۰۱۹. ۳۷۰۲۰۱۹-2040-2052. [کراس رف]
۹. لی، وای. سو، اس. آی. درباره بهبود تکرار گاو-سایدل برای تشخیص سیگنال در سیستم های MIMO عظیم چندکاربره آپ لینک. در مجموعه مقالات سومین کنفرانس بین المللی سیستم های کامپیوتری و ارتباطی (ICCCS) سال ۲۰۱۸، ناگویا، ژاپن، ۲۷ تا ۳۰ آوریل ۲۰۱۸؛ IEEE: پیسکاتوا، نیوجرسی، ایالات متحده آمریکا. ۲۰۱۸؛ صفحات ۲۶۸ تا ۲۷۲.
۱۰. جیانگ، وای.؛ وارانیسی، ام. کی.؛ لی، جی. تحلیل عملکرد برابرسازهای ZF و MMSE برای سیستم های MIMO: مطالعه ای عمیق در مورد رژیم SNR بالا. *نظریه انتقال اطلاعات IEEE*. ۲۰۲۰. ۵۷۰۲۰۱۱-۲۰۲۶-۲۰۰۸. [کراس رف]
۱۱. لارسون، EG؛ ادفورز، او. توفسون، اف. Marzetta, TL Massive MIMO برای نسل بعدی سیستم های بی سیم. *مجله ارتباطات IEEE*. ۲۰۱۴. ۵۲۰۲۰۱۴-۱۹۵-۱۸۶. [کراس رف]
۱۲. چن، س.؛ لیانگ، وای. سی.؛ سان، س.؛ کانگ، س.؛ چنگ، دبلو.؛ پنگ، م. چشم انداز، الزامات و روند فناوری نسل ششم اینترنت: چگونگی مقابله با چالش های پوشش سیستم، ظرفیت، نرخ داده کاربر و سرعت حرکت. *ارتباطات IEEE Wirel.* ۲۰۲۰. ۲۷۰۲۰۲۰-218-228. [کراس رف]
۱۳. مای، ز.؛ چن، ی.؛ دو، ل. یک الگوریتم تخمین کانال موج میلی متری کور جدید مبتنی بر ML-ELM. *نامه ارتباطی IEEE*. ۲۰۲۱. ۲۵۰۲۰۲۱-۱۵۵۳-۱۵۴۹. [کراس رف]
۱۴. کرامیدی، آی. پی.؛ موسکولوس، آی. دی.؛ ساریگیانیدیس، احتمالات مسدود کردن تماس PG تحت یک سیاست رزرو پهنای باند احتمالی در هات اسپات های تلفن همراه. *مخابرات IEEE*. ۲۰۲۱. ۵۷۳-۵۵۴. [کراس رف]
۱۵. هیث، آر دبلو؛ گونزالس-پرلچچ، ان.؛ رنگان، اس.؛ رو، دبلو.؛ سعید، ای. ام. مروری بر تکنیک های پردازش سیگنال برای سیستم های MIMO موج میلی متری. *پردازش سیگنال IEEE J. Sel. Top.* ۲۰۱۶. ۱۰۰۲۰۱۶-۴۳۶-۴۵۳. [کراس رف]
۱۶. نگوین، وی. ال. لین، پی. سی.؛ چنگ، بی. سی.؛ هوانگ، آر. اچ.؛ لین، وای. دی. امنیت و حریم خصوصی برای نسل ششم اینترنت همراه: بررسی فناوری ها و چالش های آینده. *مدرس ارتباطات، نظارت و ارزیابی IEEE*. ۲۰۲۱. ۲۳۰۲۰۲۱-۲۳۸۴-۲۴۲۸. [کراس رف]
۱۷. گائو، ایکس.؛ دای، ال.؛ یوئن، سی.؛ ژانگ، وای. تشخیص سیگنال MMSE با پیچیدگی کم مبتنی بر روش ریچاردسون برای سیستم های MIMO در مقیاس بزرگ. در مجموعه مقالات هشتمین کنفرانس فناوری خودرو (VTC2014-Fall) (IEEE 2014)، ونکوور، بریتیش کلمبیا، کانادا، ۱۴-۱۷ سپتامبر ۲۰۱۴؛ IEEE: پیسکاتوا، نیوجرسی، ایالات متحده آمریکا. ۲۰۱۴؛ صفحات ۵-۱.
۱۸. ناکای-کاسای، آ.؛ وادایاما، ت. تشخیص سیگنال MMSE برای سیستم های MIMO بر اساس معادله دیفرانسیل معمولی. در مجموعه مقالات کنفرانس ارتباطات جهانی IEEE 2022-2022 GLOBECOM، ریودوژانیرو، برزیل، ۴-۸ دسامبر ۲۰۲۲؛ IEEE: پیسکاتوا، نیوجرسی، ایالات متحده آمریکا. ۲۰۲۲؛ صفحات ۶۱۷۶-۶۱۸۱.
۱۹. جین، ف.؛ لیو، ق.؛ لیو، ج.؛ وو، پ. یک طرح تشخیص سیگنال با پیچیدگی کم مبتنی بر تکرار نیوتن بهبود یافته برای سیستم های MIMO عظیم. *نامه ارتباطی IEEE*. ۲۰۱۹. ۲۳۰۲۰۱۹-۷۵۱-۷۴۸. [کراس رف]
۲۰. هوانگ، جی بی؛ ژو، کیو وای؛ سیو، سی کی. ماشین یادگیری افراطی: نظریه و کاربردها. *محاسبات عصبی*. ۲۰۰۶. ۷۰۰۲۰۰۶-۵۰۱-۴۸۹. [کراس رف]
۲۱. هوانگ، جی بی؛ ژو، اچ.؛ دینگ، ایکس.؛ ژانگ، آر. ماشین یادگیری افراطی برای رگرسیون و طبقه بندی چندکلاسه. *سایبر (Trans. Syst. Man Cybern. Part B)*. ۲۰۱۲. ۲۳۰۲۰۱۲-۵۱۳-۵۲۹. [کراس رف] [پاب مد]
۲۲. دنگ، دبلو.؛ ژنگ، کیو.؛ چن، ال. ماشین یادگیری افراطی منظم. در مجموعه مقالات سمپوزیوم IEEE 2009 در مورد هوش محاسباتی و داده کاوی، نشویل، TE ایالات متحده آمریکا. ۳۰ مارس - ۲ آوریل ۲۰۰۹؛ صفحات ۳۸۹-۳۹۵. [کراس رف]

۲۳. ژانگ، ک.؛ لو، م. ماشین یادگیری افراطی مقاوم در برابر داده های پرت برای مسائلی رگرسیون. *محاسبات عصبی* ۱۵.۲۰۱۵، ۱۵۱۹-۱۵۲۷. [کراس رف]

۲۴. سری الدین، ح.؛ عبدالله، ع.؛ منصور، م.م.؛ آلوینی، م.س.؛ النفوری، ت.وای. MIMO-NOMA باند تراهرتز: کدگذاری تطبیقی برهم نهی و تشخیص زیرفضا. *IEEE Open J. Commun. Soc.* ۲۰۲۱، ۲۶۲۸-۲۶۴۴. [کراس رف]

**سلب مسئولیت/یادداشت ناشر:** اظهارات، نظرات و داده های موجود در تمام نشریات صرفاً متعلق به نویسندگان و مشارکت کننده (گان) است و نه MDPI و/یا سردبیر (گان). MDPI و/یا سردبیر (گان) مسئولیت هرگونه آسیب به افراد یا اموال ناشی از هرگونه ایده، روش، دستورالعمل یا محصولی که در محتوا به آن اشاره شده است را از خود سلب می کنند.